

Système intelligent d'appariement entre demandeurs d'emploi et offres d'emploi

Rapport méthodologique — Équipe DataUsis (Reine, Daïna, Emmanuelle, Angélica)

1. Contexte et problématique

L'Agence Congolaise pour l'Emploi (ACPE) reçoit chaque année des milliers d'offres d'emploi et des dizaines de milliers de profils de demandeurs, mais l'appariement entre les deux reste aujourd'hui manuel, chronophage et peu traçable. L'objectif poursuivi est la conception d'un moteur de recommandation Top-K produisant, pour chaque candidat, un classement ordonné d'offres pertinentes accompagné d'un score explicable, condition posée par le jury pour qu'une solution soit jugée exploitable par les conseillers de l'Agence.

Un audit intégral des quatre jeux de données fournis a été réalisé avant toute décision de modélisation, afin d'écartier tout risque de corruption silencieuse des métriques d'évaluation.

2. Audit de la qualité des données

Quatre fichiers ont été analysés : Offres_ACPE.xlsx (2 535 offres), Offres_ACPE_Extensions.xlsx (143 offres à texte libre), Demandeurs_.xlsx (41 298 candidats) et Appariement_Demandeurs_Offres.xlsx (vérité terrain, 3 offres pertinentes par candidat). Sept anomalies structurelles ont été identifiées et corrigées.

Anomalie	Constat	Décision
Référence d'offre dupliquée	JOB250002109 utilisée par 5 lignes distinctes (Poste 1 à 5)	Désambiguïsation par la clé composite Référence + Poste
Doublons de Matricule	13 Matricules partagés par 2 individus distincts (26 lignes)	Clé composite Matricule + suffixe de ligne
Colonne vérité terrain vide	offre_pertinente nulle à 100 %	Ground truth utilisé exclusivement depuis Appariement_Demandeurs_Offres
Secteur d'activité manquant	9,6 % de valeurs manquantes (3 984/41 298)	Catégorie explicite « Non renseigné », aucune suppression de ligne
Mobilité quasi inexploitable	« Non déclaré » pour 90,6 % des candidats	Département déduit du Matricule utilisé en repli géographique
Champ sectoriel ambigu	« Secteur demandé » ne correspond à l'offre que pour 6,2 % des cas, contre 86 % pour « secteur_metier »	Filtrage et score fondés sur secteur_metier
Extensions et fichier principal	Les 143 références sont déjà présentes dans le fichier principal	Jointure gauche sur la référence, jamais de concaténation

Une découverte complémentaire a permis de résoudre l'absence de champ de localisation candidat : le préfixe du Matricule (par exemple PPBZV, PPPNR, PPKOU) encode le département d'origine et recoupe les valeurs du champ Lieu des offres, pour l'ensemble des douze départements du Congo.

3. Architecture du moteur d'appariement

Une architecture hybride à trois couches a été retenue afin de répondre à l'exigence d'explicabilité du jury : le score est décomposé en sous-scores interprétables dès la conception, plutôt que d'appliquer un outil d'explicabilité a posteriori sur un modèle boîte noire.

- Secteur et localisation : similarité textuelle entre le secteur_metier du candidat et le secteur de l'offre, combinée à un score de localisation (département déduit du Matricule et mobilité déclarée), appliquée de façon progressive pour ne jamais produire de short-list vide.
- Texte : similarité TF-IDF sur les intitulés et qualifications, disponible pour 100 % du catalogue, enrichie par un second TF-IDF sur les champs Description/Profil/Compétences pour les 143 offres qui en disposent.
- Structure : compatibilité entre l'objectif du candidat (Emploi, Stage, Formation) et le groupe de contrat de l'offre.

Le score final résulte d'une somme pondérée des trois couches : $\text{Score} = w_1 \times \text{secteur/localisation} + w_2 \times \text{texte} + w_3 \times \text{structure}$. Les poids ont été calibrés par recherche d'hyperparamètres sur un jeu de validation de 800 candidats, distinct du jeu de test, conduisant à $w_1 = 0,21$, $w_2 = 0,70$ et $w_3 = 0,09$.

4. Protocole d'évaluation et performance du modèle

Le split entraînement/validation/test a été réalisé par candidat, jamais par ligne, afin d'éviter toute fuite d'information via les 3 offres de vérité terrain d'un même candidat. Les performances sont mesurées par Precision@K, Recall@K et NDCG@K, K = 5 et K = 10.

Indicateur	K = 5	K = 10
Precision@K	30.3 %	18.0 %
Recall@K	50.6 %	60.0 %
NDCG@K	0.507	0.550

Résultats obtenus sur un jeu de test de 8259 candidats, jamais utilisé pour la calibration des poids. Le ground truth ne contenant que 3 offres pertinentes par candidat, Precision@5 est plafonnée à 60 % et Precision@10 à 30 % dans l'absolu, indépendamment de la qualité du modèle ; les valeurs obtenues représentent donc environ la moitié du plafond théorique à K = 5 et 60 % du plafond à K = 10.

5. Fonctionnalités complémentaires

- Tableau de bord décisionnel : indicateurs macro-économiques, cartographie de tension emploi/candidats par département, distribution des scores de compatibilité, export PDF.

- Recherche en langage naturel : requête libre comparée par similarité cosinus aux offres et aux candidats, sans correspondance exacte de mots-clés.
- Analyse des écarts de compétences (Skill Gap) : compétences citées dans l'offre et absentes du profil du candidat, disponible pour les 143 offres à texte riche.
- Simulateur de compatibilité : estimation en temps réel de l'effet d'un changement de mobilité ou de l'ajout d'une compétence sur le score, sans modification du profil réel.
- Assistant contextuel local : interpréteur des recommandations et indicateurs par détection d'intention, sans dépendance à une API externe.
- Authentification par rôle (Demandeur, Recruteur, Conseiller ACPE), base SQLite, mots de passe hachés (SHA-256 salé).

Stack technique : Python, pandas et scikit-learn pour la préparation des données et le moteur TF-IDF, Streamlit pour l'interface, Plotly pour les visualisations, ReportLab pour l'export PDF.

6. Organisation du code

Le dépôt est structuré en cinq dossiers, séparant les données, la logique du moteur, l'interface et les données précalculées, conformément à l'exigence d'un dépôt organisé.

Dossier	Contenu
data/	Quatre jeux de données bruts fournis par les organisateurs (fichiers Excel), non modifiés.
moteur/	Logique métier : préparation et nettoyage des données (data_prep.py), moteur d'appariement à 3 couches (matching.py), calibration des poids et évaluation (calibrate_weights.py, evaluation.py, final_evaluation.py), extraction de compétences d'un CV (cv_parser.py, skills.py), recherche en langage naturel (search.py), assistant contextuel (chatbot.py), authentification (auth.py), export PDF (pdf_report.py).
application/	Interface Streamlit : point d'entrée unique (main.py), styles et composants communs (common.py), une page par profil dans pages/ (login, demandeur, recruteur, conseiller), images de fond dans images/.
donnees_generees/	Données précalculées : recommandations pour l'ensemble des candidats, statistiques du tableau de bord, résultats d'évaluation, base des comptes utilisateurs (SQLite).
api/	API REST optionnelle exposant le moteur pour un accès programmatique (non nécessaire à l'utilisation de l'application).

L'application se lance avec la commande streamlit run application/main.py.

7. Accès de démonstration pour le jury

Un compte a été créé à l'avance pour chacun des trois profils applicatifs : le jury n'a besoin de créer aucun compte pour tester l'outil. Le lancement de l'application affiche uniquement la page de connexion ; l'accès aux fonctionnalités de chaque profil s'effectue directement après authentification avec les identifiants ci-dessous.

Profil	Email	Mot de passe
Demandeur d'emploi	jury.demandeur@acpematcher.cg	Jury2026Demandeur
Offreur d'emploi (Recruteur)	jury.recruteur@acpematcher.cg	Jury2026Recruteur
Conseiller / Administrateur ACPE	jury.conseiller@acpematcher.cg	Jury2026Conseiller

8. Points innovants

- Reconstruction d'une donnée absente : aucune colonne de localisation n'existait pour les candidats ; le département a été déduit du préfixe du Matricule plutôt que d'être ignoré, ce qui a rendu possible la couche secteur/localisation pour l'ensemble des candidats.
- Explicabilité par construction : le score n'est pas une boîte noire expliquée a posteriori, il est nativement décomposé en trois sous-scores interprétables (secteur/localisation, texte, structure), directement restitués à l'utilisateur.
- Pondération calibrée empiriquement : les poids du modèle hybride résultent d'une recherche d'hyperparamètres comparant règles seules, texte seul et hybride sur un jeu de validation, plutôt que d'un choix arbitraire.
- Accès élargi au-delà du dataset fourni : un candidat absent de la base ACPE peut créer un profil en téléversant simplement son CV, dont les compétences sont extraites automatiquement et injectées dans le même moteur de recommandation.
- Simulateur d'impact « et si ? » : le candidat peut estimer, avant d'agir, l'effet d'une compétence à acquérir ou d'un changement de mobilité sur son score de compatibilité avec une offre donnée, transformant le moteur en outil d'orientation proactif plutôt que descriptif.